



Documentation

Supported Models - GroqDocs

GPT OSS 120B

openai/gpt-oss-120b

[Spróbuj w Playground](#)

PRĘDKOŚĆ TOKENA

~500 tps

Powered przez

WKŁAD

T

Tekst

WYJŚCIE

T

Tekst

MOŻLIWOŚCI

Wykorzystanie
Narzędzia, Wyszukiwanie
Przeglądarki, Wykonanie
Kodu, Tryb Obiektu
JSON, Tryb Schematu
JSON, Rozumowanie



OpenAI

[Karta modelu](#)

Flagowy model MoE o otwartej wadze OpenAI z łącznymi parametrami 120B. Zaprojektowany do użytku agentowego o wysokiej zdolności, pasuje lub przewyższa zastrzeżone modele, takie jak OpenAI o4-mini, na wielu benchmarkach. Dzięki długotrwałemu rozumowaniu kontekstowemu, konkurencyjnej wydajności matematycznej / kodowania i solidnej wiedzy zdrowotnej jest idealny do zaawansowanych badań, autonomicznych narzędzi i zastosowań agentycznych.

CENY

Wejście	Wbudowane wejście	Wyjście
\$0,15 6,7M / \$1	\$0.075 13M / \$1	\$0,60 1.7M / \$1

LIMITY

OKNO KONTEKSTU131,072

MAKSYMALNE TOKENY WYJŚCIOWE65,536

KWANTYZACJA

Wykorzystuje to numery TruePoint firmy Groq, które zmniejszają precyzję tylko w obszarach, które nie wpływają na dokładność, zachowując jakość, jednocześnie zapewniając znaczne przyspieszenie w stosunku do tradycyjnych podejść. [Dowiedz się więcej tutaj](#) .

Kluczowe specyfikacje techniczne

Architektura modelu

Zbudowany na architekturze Mixture-of-Experts (MoE) z parametrami całkowitymi 120B (5.1B aktywny na przepustkę do przodu). Posiada 36 warstw ze 128 ekspertami MoE przy użyciu Top-4 routeing na token. Wyposażony w zgrupowaną uwagę zapytania i osadzenia obrotowe, przy użyciu normalizacji wstępnej RMSNorm z szerokością rezydualną 2880.

Metryki wydajności

Model GPT-OSS 120B wykazuje wyjątkową wydajność w kluczowych punktach odniesienia:

- MMLU (Rozumowanie ogólne): 90,0%
- SWE-Bench Verified (Kodowanie): 62,4%
- HealthBench Realistic (Zdrowie): 57,6%
- MMMLU (Wielojęzyczne): 81,3% średnia

Przypadki użycia

Aplikacje agentowe klasy granicznej

Wdrożenie dla autonomicznych agentów o wysokiej zdolności dzięki zaawansowanemu rozumowaniu, wykorzystaniu narzędzi i wieloetapowemu rozwiązywaniu problemów, które pasuje do zastrzeżonej wydajności modelu.

Zaawansowane badania i obliczenia naukowe

Idealny do zastosowań badawczych wymagających solidnej wiedzy zdrowotnej, analizy bezpieczeństwa biologicznego i rozumowania naukowego z silnym dostosowaniem bezpieczeństwa.

Zadania matematyczne i kodujące o wysokiej dokładności

Wyróżnia się w konkurencyjnym programowaniu, złożonym rozumowaniu matematycznym i zadaniach inżynierii oprogramowania z najnowocześniejszym benchmarkiem.

Wielojęzyczni Asystenci AI

Twórz zaawansowane aplikacje wielojęzyczne o wysokiej wydajności w ponad 81 językach i kontekstach kulturowych.

Najlepsze praktyki

- Wykorzystaj zmienne tryby rozumowania (niskie, średnie, wysokie) w celu zrównoważenia

wydajności i opóźnienia w oparciu o określone wymagania dotyczące przypadku użycia.

- Wykorzystaj format czatu Harmony z odpowiednią hierarchią ról (System > Programista > Użytkownik > Asystent) dla optymalnej instrukcji i zgodności z bezpieczeństwem.
- Skorzystaj z testów gotowości modelu do badań nad bezpieczeństwem biologicznym i dostosowaniem przy jednoczesnym poszanowaniu granic bezpieczeństwa.
- Użyj pełnego okna kontekstowego 131K, aby uzyskać złożone, wieloetapowe przepływy pracy i kompleksową analizę dokumentów.
- Definicje narzędzi strukturalnych jasno podczas korzystania z przeglądania stron internetowych, wykonywania Pythona lub funkcji wywoływania funkcji dla uzyskania najlepszych wyników.

Wprowadzenie do GPT-OSS 120B

Doświadczenie `openai/gpt-oss-120b` na Groq:

zwiń JavaScript Pythona JSON

muszla



```
pip install groq
```

Pythona



```
1 from groq import Groq
2 client = Groq()
3 completion = client.chat.completions.create(
4     model="openai/gpt-oss-120b",
5     messages=[
6         {
7             "role": "user",
8             "content": "Explain why fast inference is critical for reasoning models"
9         }
10    ]
11 )
12 print(completion.choices[0].message.content)
```

Czy ta strona była pomocna?

☐ Tak

☐ Nie

☐ Zaproponuj Edycje

Docs

